ĐẠI HỌC
BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY
OF SCIENCE AND TECHNOLOGY

DỰ BÁO NGUY CƠ TÁI NHẬP VIỆN 30 NGÀY Ở BỆNH NHÂN SUY TIM TỪ DỮ LIỆU BỆNH ÁN ĐIỆN TỬ BẰNG MÔ HÌNH HỌC MÁY GIẢI THÍCH ĐƯỢC (EXPLAINABLE AI)

GVHD: Ths. Hoàng Quang Huy
Mã lớp: 176336
Mã HP: ET4248
Nhóm: 10
SV thực hiện: Lê Thu Trang - 20233815
Lê Thúy Hằng - 20233749

ONE LOVE. ONE FUTURE.

MỤC LỤC

1. Bối cảnh lâm sàng & Tính cấp bách
2. Phát biểu bài toán & Phân tích chi phí sai số
3. Tổng quan y văn
4. Khoảng trống nghiên cứu
5. Dataset
6. EDA
7. Qui trình tiền xử lý
8. Xây dựng mô hình baseline
9. Timeline
10. Workflow

Bối cảnh lâm sàng & Tính cấp bách

- Suy tim là bệnh mạn tính có tỷ lệ nhập viện và tái nhập viện cao, đặc biệt trong giai đoạn sớm sau xuất viện.
- Tái nhập viện trong 30 ngày là một chỉ số quan trọng phản ánh nguy cơ biến cố sau điều trị và chất lượng chăm sóc.
- Việc xác định sớm bệnh nhân có nguy cơ cao giúp bác sĩ theo dõi sát hơn, tối ưu điều trị và lập kế hoạch chăm sóc sau xuất viện.
- Dữ liệu bệnh án điện tử chứa nhiều thông tin có giá trị như tuổi, tiền sử nhập viện, chẩn đoán, thuốc, xét nghiệm và thời gian nằm viện.
- Đề tài sử dụng học máy kết hợp Explainable AI để dự báo nguy cơ tái nhập viện 30 ngày và giải thích các yếu tố ảnh hưởng đến dự đoán.



→ **Mục tiêu lâm sàng:** hỗ trợ nhận diện sớm bệnh nhân suy tim có nguy cơ tái nhập viện cao trong vòng 30 ngày sau xuất viện.

Phát biểu bài toán

Câu hỏi nghiên cứu: Làm thế nào để xây dựng một mô hình học máy vừa dự báo chính xác nguy cơ tái nhập viện trong vòng 30 ngày ở bệnh nhân suy tim từ dữ liệu bệnh án điện tử, vừa định lượng và giải thích các đặc trưng đóng góp vào dự đoán nguy cơ đó nhằm hỗ trợ bác sĩ can thiệp điều trị cá thể hóa

INPUT	OUTPUT
1. Demographics • Age • Gender • Race • Insurance • Marital status **2. Admission & Utilization** • LOS • Prior admissions • Prior HF admissions • Admission type/location • Discharge location **3. Clinical characteristics** • Diagnoses & comorbidities • Procedures • Medication groups **4. Laboratory** • Creatinine • BUN • Sodium • Potassium • Hemoglobin • Glucose • Calcium • các xét nghiệm phù hợp khác **5. OMR / Clinical measurements** • BMI • Weight • Systolic/Diastolic BP • eGFR → **Final pre-model dataset:** 46 predictors trước One-Hot Encoding.	**Nhãn phân loại nhị phân:** • Y = 1: Có tái nhập viện trong vòng 30 ngày sau xuất viện. • Y = 0: Không tái nhập viện trong vòng 30 ngày sau xuất viện. **Xác suất dự đoán:** Mô hình trả về xác suất bệnh nhân tái nhập viện trong vòng 30 ngày (0–100%), hỗ trợ đánh giá mức độ nguy cơ và phân loại bệnh nhân. **Giải thích dự đoán:** Định lượng mức độ đóng góp của từng đặc trưng vào dự đoán bằng SHAP.

Phân tích chi phí sai số bất đối xứng

Kịch bản Âm tính giả	Kịch bản Dương tính giả
• Dự báo: Bệnh nhân có nguy cơ thấp → không được ưu tiên theo dõi tăng cường. • Thực tế: Bệnh nhân tái nhập viện trong vòng 30 ngày. • Hệ quả: Có thể bỏ sót bệnh nhân nguy cơ cao, làm chậm theo dõi và can thiệp sau xuất viện	• Dự báo: Bệnh nhân có nguy cơ tái nhập viện cao → được tăng cường theo dõi. • Thực tế: Bệnh nhân không tái nhập viện trong vòng 30 ngày. • Hệ quả: Tăng số lần theo dõi/tái khám không cần thiết, làm tăng chi phí và sử dụng nguồn lực y tế.

→ Chi phí của âm tính giả lớn hơn dương tính giả vì bỏ sót bệnh nhân có nguy cơ tái nhập viện. Do đó, mô hình cần ưu tiên khả năng phát hiện ca nguy cơ cao (Recall/Sensitivity), đồng thời kiểm soát số lượng cảnh báo giả.

Chiến lược khảo sát y văn

- Nguồn dữ liệu: PubMed, IEEE Xplore, Google Scholar.
- Từ khóa tìm kiếm (Keywords): ("Heart failure" OR "HF"), ("Readmission" OR "30-day"), ("Machine learning" OR "XGBoost"), ("Electronic Health Records" OR "EHR"), ("Explainable AI" OR "SHAP")

Tổng quan y văn

STT	Năm, tạp chí	Tiêu đề	Tác giả	Bộ dữ liệu, cỡ mẫu	Kiến trúc mô hình	Kết quả	Đóng góp chính	XAI	DOI
1	2025, ESC Heart Failure	Predicting acute decompensated heart failure using circadian markers from heart rate time series	Niek J. van Es, et al.	N = 65 bệnh nhân suy tim sau đợt cấp ADHF (426 chuỗi 21 ngày; tỷ lệ ổn định : đợt cấp = 391:35). Đo nhịp tim liên tục bằng cảm biến đeo.	Phân tích Cosinor (trích xuất Mesor, Biên độ, Đỉnh pha) -> LSTM (100 units); Kiểm định Leave-One-Patient-Out (LOOCV)	AUC = 0.74, Sensitivity = 74%, Specificity = 73%, NPV = 97%, PPV = 20%, F1 = 31%, AUPRC = 0.21	Chứng minh sự gián đoạn nhịp sinh học ngày/đêm của nhịp tim (suy giảm biên độ dao động sinh học) diễn ra trước đợt cấp suy tim mất bù, mở ra khả năng cảnh báo sớm từ xa trước nhiều tuần.	Không	10.1002/ehf2.15395
2	2026, BMC Medical Informatics and Decision Making	Explainable machine learning model for early prediction of ICU death in chronic heart failure with pulmonary infection	Jin Zhai, et al.	Dữ liệu nội bộ: N = 1.308 (MIMIC-IV); Dữ liệu kiểm định ngoại viện độc lập: N = 365 (eICU-CRD).	Xử lý dữ liệu bảng bệnh án điện tử với 37 biến lâm sàng. Điền khuyết bằng MICE, xử lý mất cân bằng lớp bằng SMOTE-Tomek. So sánh 6 mô hình học máy (LR, RF, LightGBM, XGBoost, MLP, KNN).	Nội bộ (XGBoost): AUC = 0.968, Acc = 90.6%, F1 = 90.6%, Precision = 89.4%, Recall = 91.7%. Ngoại viện: AUC = 0.718, Acc = 76.3%, Recall = 38.3%.	Thiết lập quy trình học máy hoàn chỉnh cho suy tim có cơ chế giải thích lâm sàng đa tầng (SHAP Beeswarm và LIME từng ca bệnh); cung cấp số liệu thực nghiệm về hiện tượng trượt phân phối dữ liệu giữa các bệnh viện.	SHAP toàn cục và LIME giải thích từng ca bệnh	10.1186/s12911-026-03682-z
3	2025, Frontiers in Cardiovascular Medicine	Machine learning-based prediction model for 30-day readmission risk in elderly patients with type 2 diabetes mellitus and heart failure: a retrospective cohort study with SHAP interpretability analysis	Lei Wang, et al.	Thiết kế hồi cứu trên N = 870 bệnh nhân cao tuổi mắc đồng thời đái tháo đường tuýp 2 (T2DM) và suy tim.	Phương pháp học kết hợp (Stacking Ensemble).	Mô hình đạt AUC = 0.867 cho dự báo tái nhập viện 30 ngày.	Phân tích diễn giải thông qua SHAP (nêu trực tiếp trên tiêu đề).	Phân tích SHAP mức độ tổng thể	10.3389/fcvm.2025.1673159
4	2026, Medical & Biological Engineering & Computing	Predicting 30-day readmission after heart failure hospitalization using interpretable machine learning: evidence from a 20-year population-based rural registry	Jorge Maese-Calvo, et al.	Cơ sở dữ liệu đăng ký (registry) y tế nông thôn kéo dài 20 năm, N ~ 5.000.	So sánh Random Forest (RF), XGBoost, SVM với mô hình đối chứng Logistic Regression.	Random Forest vượt trội với AUC = 0.812 (so với 0.686 của Baseline LR).	Chứng minh sự ổn định của Random Forest trên tập dữ liệu dài hạn.	Sử dụng SHAP để định lượng mức độ đóng góp của từng đặc trưng.	10.1007/s11517-026-03657-2
5	2024, *iScience* (Cell Press)	Explainable machine learning for predicting 30-day readmission in acute heart failure patients	Yang Zhang, Tianyu Xiang, Yanqing Wang, et al.	N = 2.232 bệnh nhân suy tim cấp (AHF) nhập viện nội trú (tỷ lệ tái nhập viện 30 ngày là 6,72%).	Sàng lọc đặc trưng qua hệ số phóng đại phương sai (VIF) kết hợp kiểm định chéo 5-fold. So sánh 5 thuật toán (LR, SVM, RF, LightGBM, XGBoost).	XGBoost: AUC = 0.763 (95% CI: 0.703–0.824), Acc = 70.9%, Sensitivity = 66.0%, Specificity = 74.2%.	Xếp hạng định lượng các yếu tố nguy cơ độc lập trong suy tim cấp (bề dày vách liên thất, tuổi, EF, thời gian nằm viện LOS, Albumin) thông qua SHAP.	SHAP TreeExplainer xếp hạng các biến: bề dày vách liên thất, tuổi, EF, thời gian nằm viện LOS, Albumin	10.1016/j.isci.2024.110281
6	2018, BMC Medical Informatics and Decision Making	A machine learning model to predict the risk of 30-day readmissions in patients with heart failure: a retrospective analysis of electronic medical records data	S. B. Golas, T. Shibahara, S. Agboola, et al.	N = 20.301 đợt điều trị nội trú từ 10.052 bệnh nhân suy tim (dữ liệu bệnh án điện tử EMR đa biến).	Mạng nơ-ron sâu (Deep Neural Network - DNN); so sánh đối chứng với Random Forest, Logistic Regression và thang điểm LACE.	DNN: AUC = 0.705, Acc = 65.4%, Sensitivity = 63.8%, Specificity = 67.1%, Precision = 44.8%. Baseline LR: AUC = 0.664; thang điểm LACE: AUC = 0.612.	Chứng minh mô hình học máy khai thác bệnh án điện tử vượt trội hơn các thang điểm thủ công truyền thống (LACE) trong dự báo nguy cơ tái nhập viện suy tim.	Không	10.1186/s12911-018-0620-z

Tổng quan y văn

7	2019, ESC Heart Failure	Machine learning-based prediction of heart failure readmission or death: implications of choosing the right model and the right metrics	Saqib Ejaz Awan, Mohammed Bennamoun, Ferdous Sohel, et al.	N = 10.757 bệnh nhân cao tuổi (từ 65 tuổi) nhập viện vì suy tim (tỷ lệ tái nhập viện/tử vong 30 ngày là 23,6%).	Tiếp cận cân bằng trọng số lớp (Class-balanced) trên Mạng Perceptron đa tầng (MLP); đối chứng với Weighted RF, Weighted SVM, Logistic Regression.	MLP: AUC = 0.62, AUPRC = 0.46, Sensitivity = 48.0%, Specificity = 70.0%. Các mô hình cơ bản khác chỉ đạt AUC từ 0.53 đến 0.58; Baseline LR: AUC = 0.58).	Khẳng định tầm quan trọng của việc lựa chọn đúng hệ chỉ số đánh giá (AUPRC, Sensitivity thay vì chỉ nhìn vào Accuracy/AUROC) khi xử lý bài toán dữ liệu y tế mất cân bằng lớp.	Không	10.1002/ehf2.12419
8	2025, Postgraduate Medical Journal	Machine learning approaches for predicting heart failure readmissions	Amaia Pikatza-Huerga, et al.	Bệnh nhân suy tim cấp (AHF). Dữ liệu mất cân bằng nặng (16% tái nhập viện trong 30 ngày, 84% không tái nhập viện).	Ensemble ML (Decision trees, Naive Bayes, Neural networks) so sánh với Cox và Logistic Regression. Cân bằng dữ liệu bằng SMOTE.	Mô hình Ensemble đạt AUC = 0.81. Vượt trội hoàn toàn so với Cox (AUC = 0.58) và Logistic Regression (AUC = 0.50).	Phân tích SHAP phát hiện 3 yếu tố dự báo hàng đầu: hội chứng suy yếu (frailty), lo âu và trầm cảm.	SHAP Summary Plot	10.1093/postmj/qgaf102
9	2024, Scientific Reports	SHAP based predictive modeling for 1 year all-cause readmission risk in elderly heart failure patients: feature selection and model interpretation	Hao Luo, et al.	N = 8.396 bệnh nhân suy tim cao tuổi (hồi cứu 2018-2021). Sử dụng 73 đặc trưng lâm sàng đầu vào.	Khung Human-Machine: Kết hợp đặc trưng do Máy chọn (XGBoost, LASSO, RF) và Chuyên gia chọn. Đào tạo bằng CatBoost.	Mô hình kết hợp đạt AUC = 0.836, F1-score = 0.735, Brier score = 0.165.	SHAP trực quan hóa 5 đặc trưng rủi ro nhất: Hemoglobin (HGB), NT-proBNP, tiền sử hút thuốc, NYHA, và LVEF.	Giải thích đa hướng với CatBoost và SHAP	10.1038/s41598-024-67844-7
10	2023, JMIR Medical Informatics	The Price of Explainability in Machine Learning Models for 100-Day Heart Failure Readmission	Amira Soliman, et al.	N = 15.612 ca nhập viện do suy tim. Tỷ lệ bệnh nhân tái nhập viện là 35,85% (5.597 ca).	So sánh đối đầu giữa Deep Learning (hộp đen) và Explainable Shallow ML (Học máy nông) kết hợp Feature Engineering sâu.	Explainable ML đạt hiệu năng tương đương Deep Learning và vượt qua tất cả các thang điểm lâm sàng truyền thống.	Khả năng giải thích cục bộ được tối ưu hóa nhằm tăng độ tin cậy cho bác sĩ khi quyết định tại điểm chăm sóc.	Phân tích đánh đổi giữa độ chính xác và khả năng diễn giải	10.2196/46934
11	2025, JMIR Medical Informatics	Predicting 30-Days Hospital Readmission for Patients with Heart Failure Using Electronic Health Record Embeddings: Comparative Evaluation	Prabin Shakya, Anurag Khaneja, Kavishwar B. Wagholikar	Cơ sở dữ liệu MIMIC-IV. Tập trung vào nhóm bệnh nhân suy tim (Heart Failure), tuổi trung bình 73, tỷ lệ tái nhập viện trong 30 ngày là 19%.	So sánh phương pháp trích xuất đặc trưng (embeddings) cho hồ sơ bệnh án điện tử (EHR): Code-based embeddings (như word2vec) so với Text-based embeddings (như BERT). Mô hình phân loại: Logistic Regression, XGBoost, ANN.	Code-based embeddings đạt hiệu suất tốt nhất (AUROC = 0.65) so với baseline one-hot encoding (AUROC = 0.54). Text-based embeddings cho kết quả kém nhất.	Cung cấp bằng chứng thực nghiệm về việc biểu diễn dữ liệu bằng code-based embeddings mang lại hiệu quả ưu việt hơn so với text-based embeddings đối với dữ liệu EHR có cấu trúc.	Không	10.2196/73020

Khoảng trống nghiên cứu & Đóng góp

Khoảng trống

- **Nguy cơ rò rỉ dữ liệu và đánh giá quá lạc quan:** Một bệnh nhân có thể có nhiều lần nhập viện; nếu chia dữ liệu theo từng admission, cùng một bệnh nhân có thể xuất hiện ở cả train và test.
- **Khả năng giải thích còn hạn chế:** Feature importance toàn cục chưa cho biết tại sao mô hình đưa ra cảnh báo cho một bệnh nhân cụ thể.
- **Chi phí sai số không đối xứng:** Bỏ sót bệnh nhân nguy cơ cao (False Negative) có hậu quả lớn hơn việc cảnh báo nhầm, nên Accuracy đơn thuần chưa đủ để đánh giá mô hình.

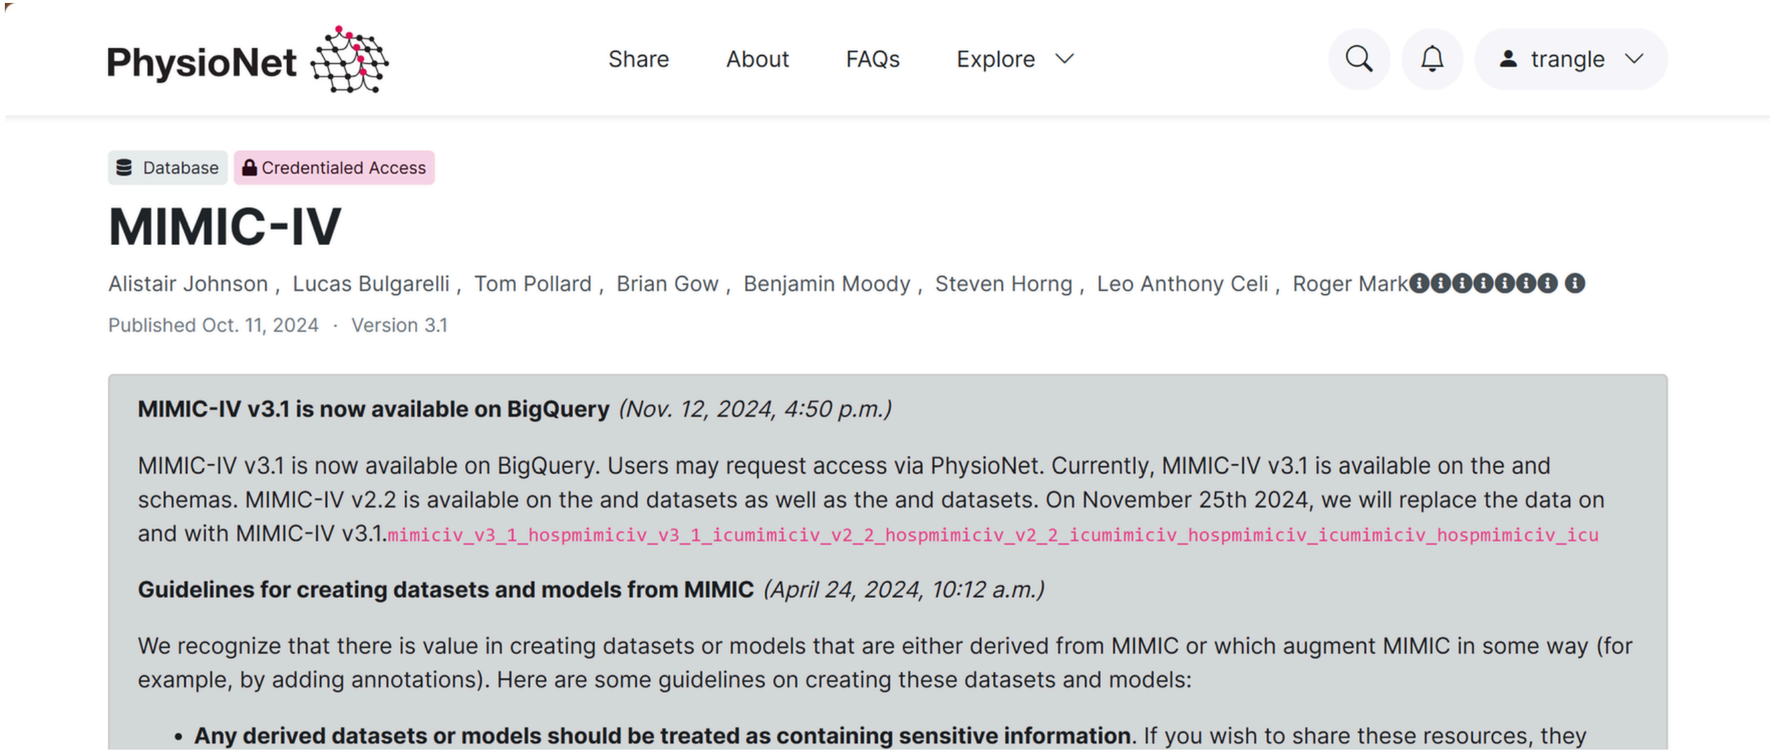
Đóng góp

- **Đánh giá theo mức bệnh nhân:** Sử dụng Patient-level split / Stratified Group K-Fold để tất cả admission của cùng một bệnh nhân nằm trong cùng một fold, hạn chế data leakage.
- **So sánh mô hình cơ sở và mô hình boosting:** Sử dụng Logistic Regression làm baseline; tiếp tục đánh giá XGBoost/LightGBM để cải thiện khả năng dự báo
- **Explainable AI ở cả mức toàn cục và cá thể:** Sử dụng SHAP/TreeSHAP để xác định đặc trưng quan trọng và giải thích dự đoán của từng bệnh nhân.
- **Tối ưu theo mục tiêu lâm sàng:** Ưu tiên Recall/Sensitivity, AUPRC và AUROC, đồng thời điều chỉnh ngưỡng dự đoán để giảm nguy cơ bỏ sót bệnh nhân.

Dataset

Dataset chính – MIMIC-IV Clinical Database v3.1

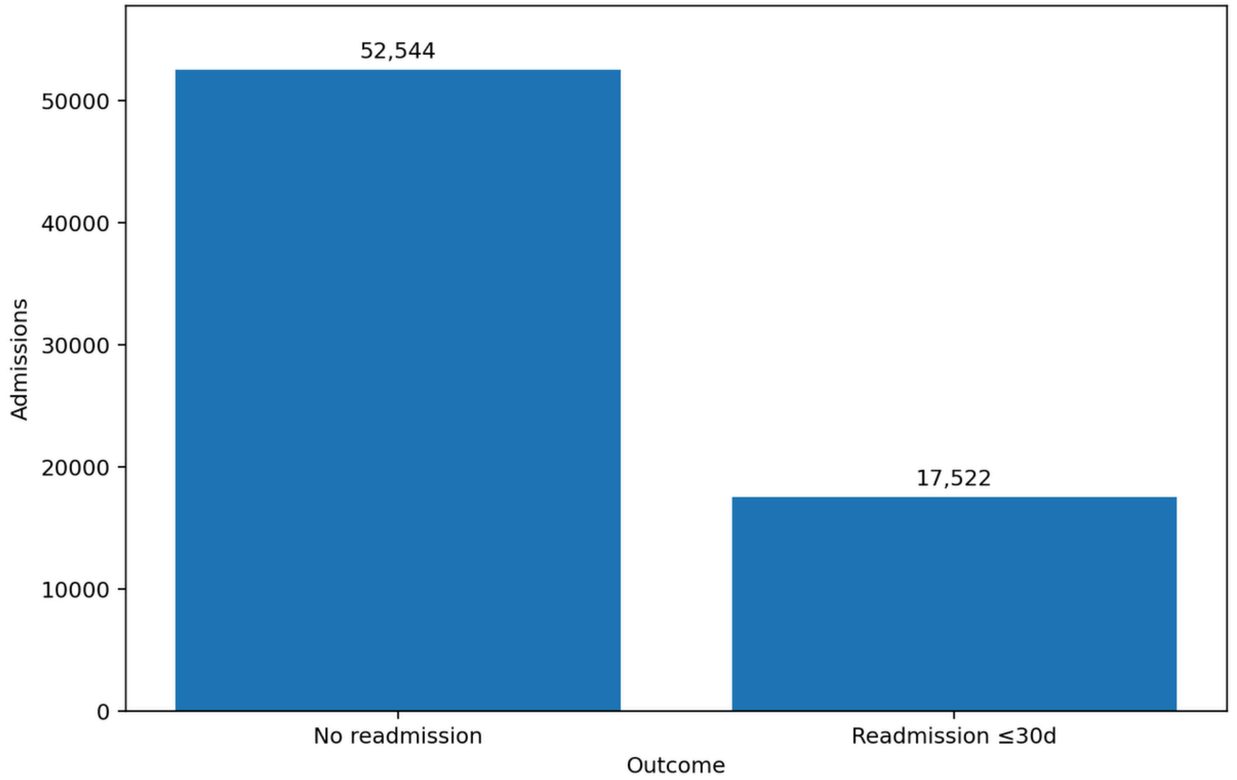
- Quyền truy cập PhysioNet đã được phê duyệt.
- Dữ liệu đầy đủ đã được tải và xử lý từ module hosp.
- Đã hoàn thành xây dựng cohort suy tim, tạo nhãn tái nhập viện 30 ngày và xây dựng đặc trưng.
- Dataset cuối sẵn sàng cho giai đoạn huấn luyện mô hình.



EDA

Tổng quan cohort & phân bố dữ liệu

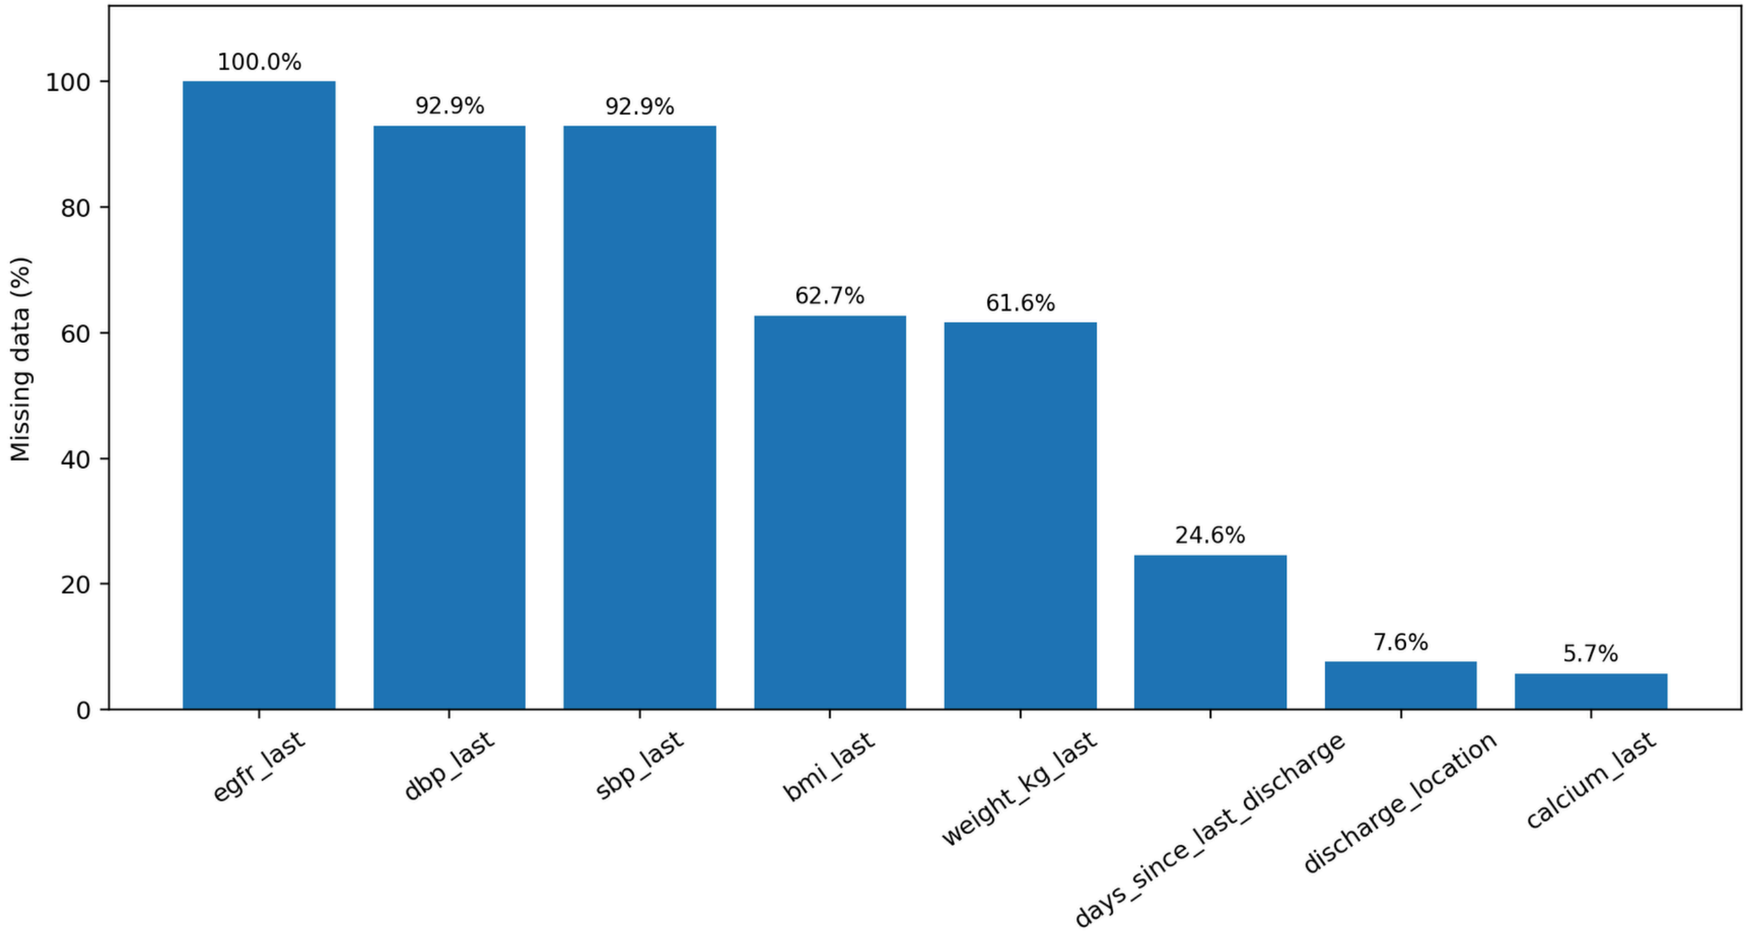
Thông tin	Kết quả
HF patients	28.376
HF admissions	70.066
Readmission ≤30 ngày	17.522
Non-readmission	52.544
Readmission rate	25.01%
Tuổi trung vị	75
Male / Female	53.2% / 46.8%



Patient-level imbalance:

- Có ít nhất một readmission: 8,622 bệnh nhân
- Không có readmission: 19,754 bệnh nhân

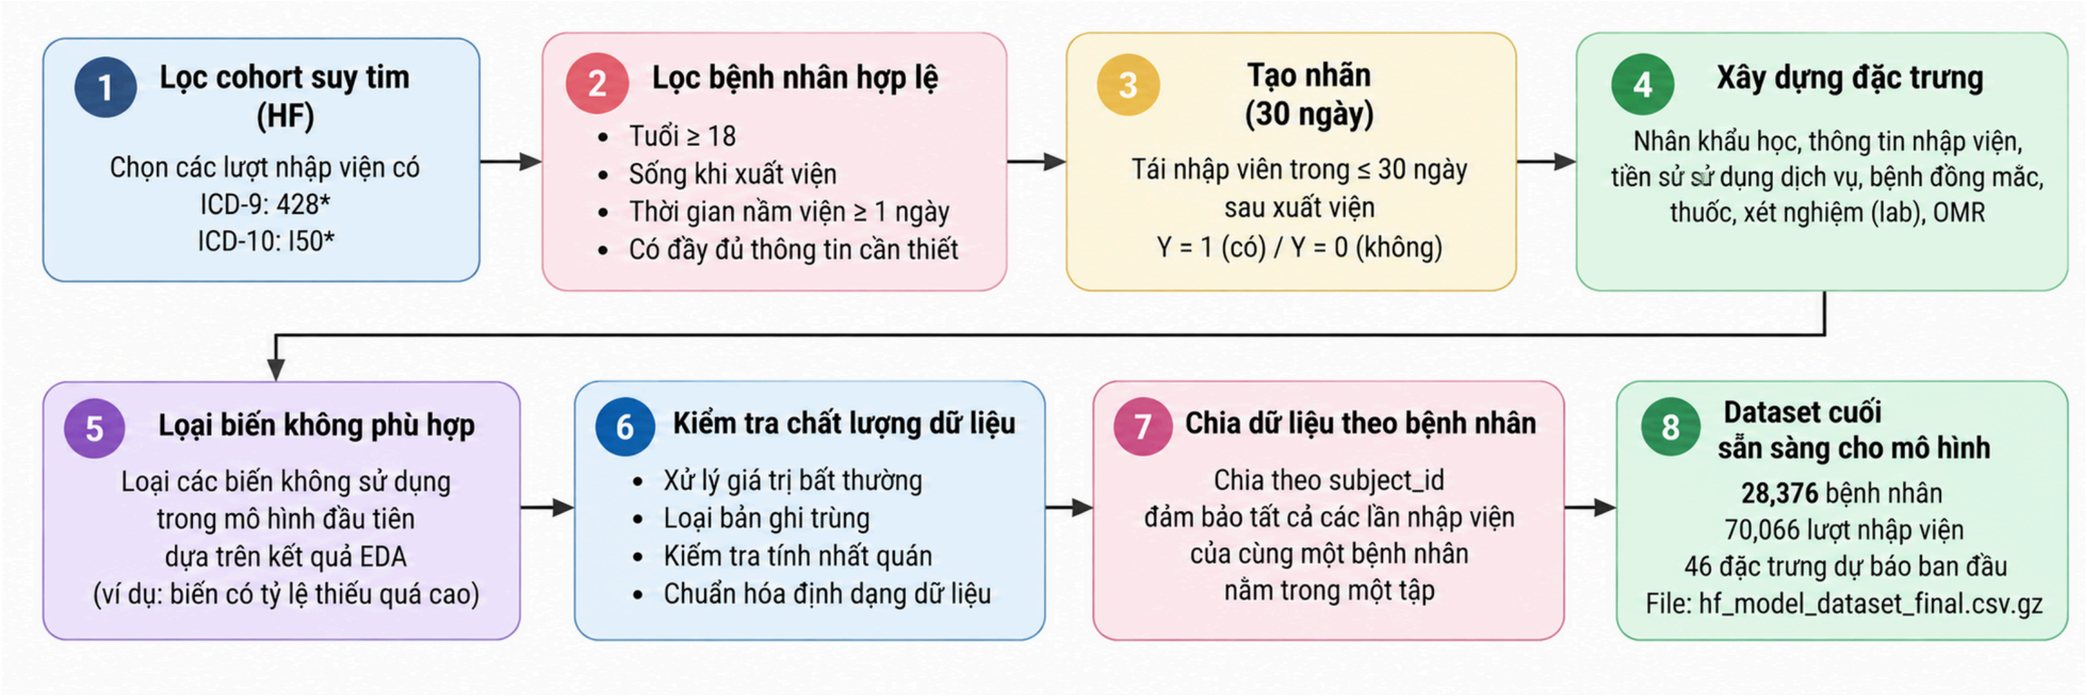
EDA – Missing Data & Correlation Analysis



- Loại các biến: eGFR, SBP, DBP, BMI, Weight do missing >60%.
- Giữ biến days_since_last_discharge dù thiếu 24.6% vì đây là thiếu có cấu trúc.
- Các lab chính còn lại missing <6% → giữ và impute trên Train.

Qui trình tiền xử lý dữ liệu

Pipeline tiền xử lý dữ liệu



Mỗi hàng của dataset cuối tương ứng với một lượt nhập viện suy tim và được dùng để dự báo nguy cơ tái nhập viện trong 30 ngày sau xuất viện.

Qui trình tiền xử lý dữ liệu

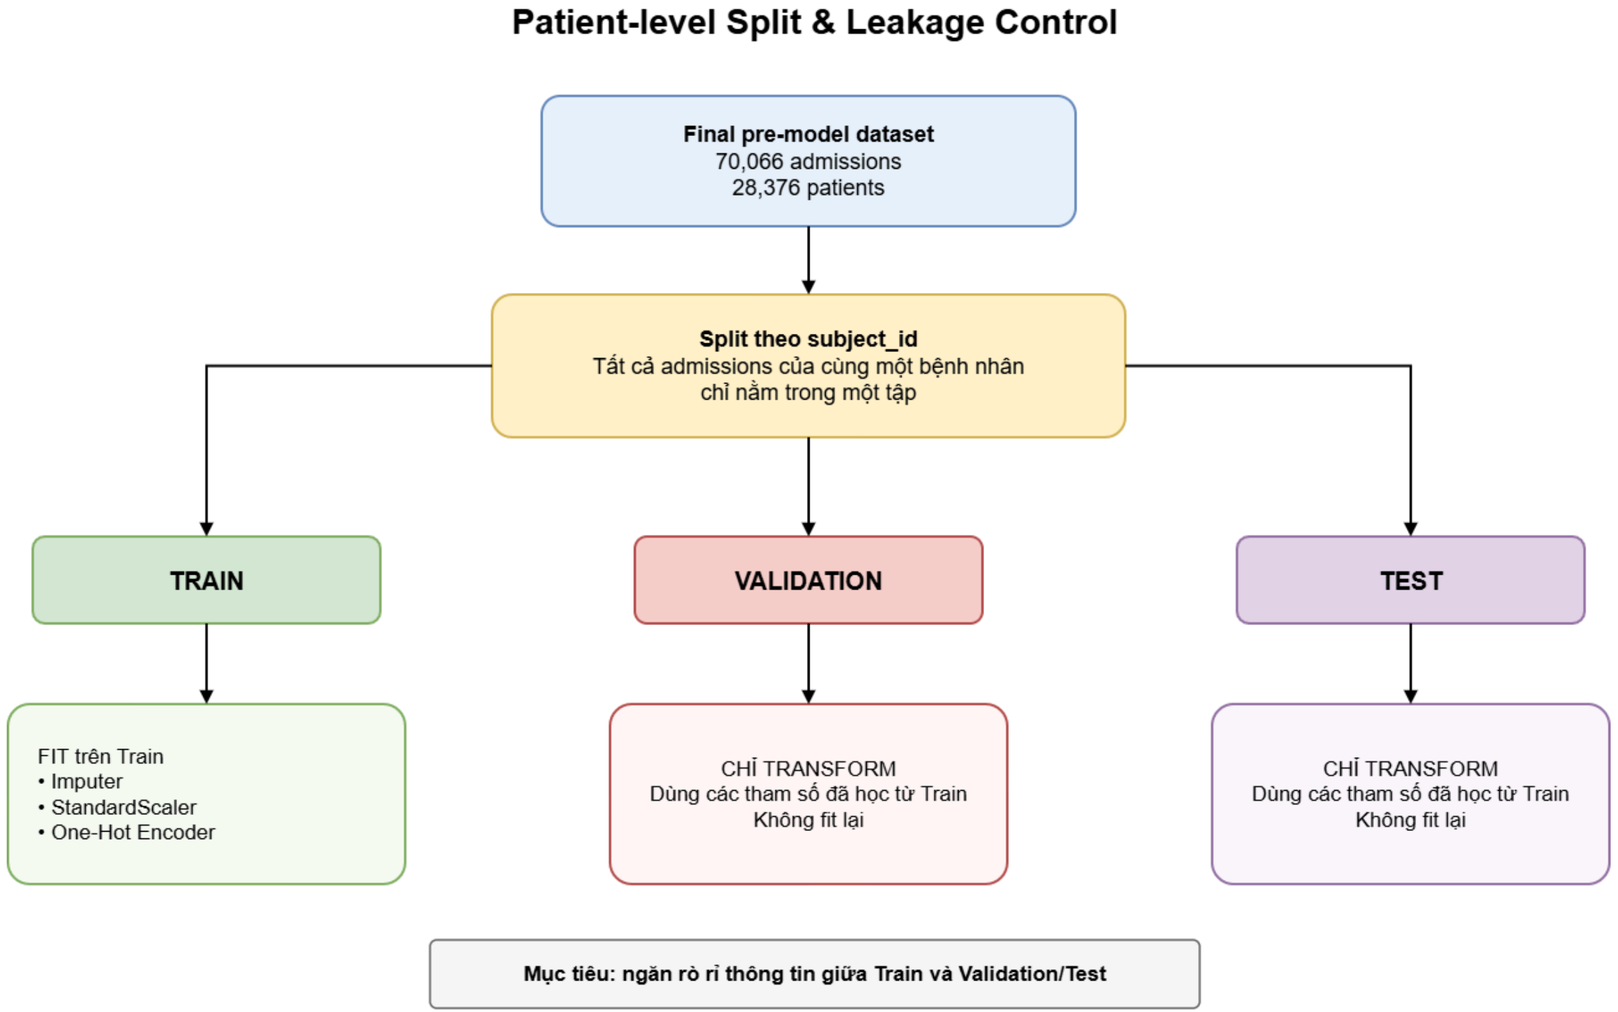
Feature Engineering - Xây dựng đặc trưng

Nhóm	Đặc trưng tiêu biểu
Nhân khẩu học	Age, Gender, Race, Insurance
Thông tin nhập viện	LOS, Admission type/location, Discharge location
Tiền sử sử dụng dịch vụ	Prior admissions, prior HF admissions, 30/90/365 ngày
Bệnh đồng mắc	Diabetes, CKD, COPD, AF, CAD, Anemia
Thủ thuật	Number of procedures
Thuốc	Beta blocker, ACEI/ARB/ARNI, MRA, Loop diuretic, SGLT2i
Xét nghiệm	Creatinine, BUN, Na, K, Hb, WBC, Platelet, Glucose...
OMR	BMI, Weight, BP, eGFR

- 41 predictors trước bước mã hóa biến phân loại
- Một số biến OMR có tỷ lệ thiếu quá cao được loại khỏi mô hình đầu tiên dựa trên kết quả EDA.

Qui trình tiền xử lý dữ liệu

Patient-level Split & Leakage Control for Model Training



→ Output: **hf_model_dataset_final.csv.gz** — sẵn sàng cho bước xây dựng mô hình.

Sử dụng mô hình baseline

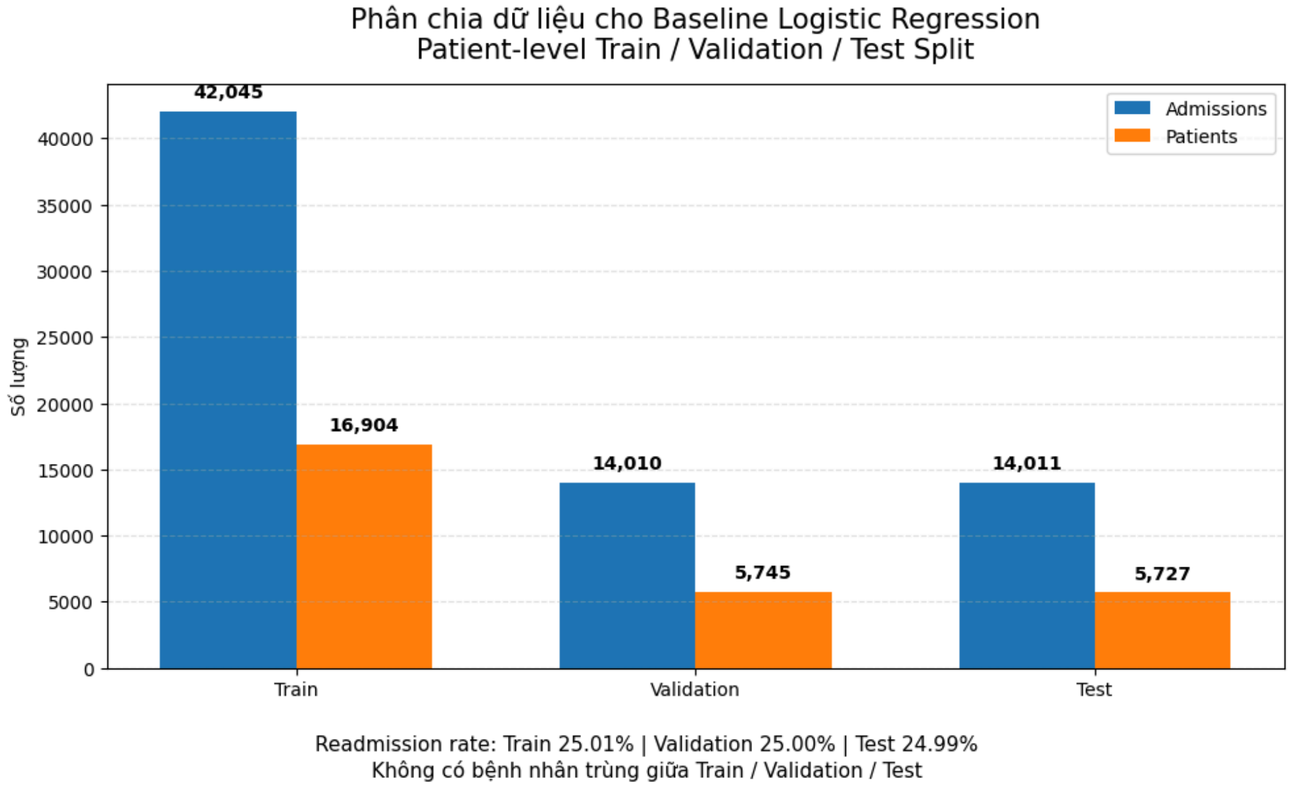
Phân chia dữ liệu ở mức bệnh nhân

Train – 60%
- 42.045 lượt nhập viện
- 16.904 bệnh nhân
- Tỷ lệ tái nhập viện: 25,01%
- Dùng để fit Imputer, StandardScaler, One-Hot Encoding và huấn luyện mô hình.

Validation – 20%
- 14.010 lượt nhập viện
- 5.745 bệnh nhân
- Tỷ lệ tái nhập viện: 25,00%
- Dùng để lựa chọn mô hình, hyperparameter và threshold.

Test – 20%
- 14.011 lượt nhập viện
- 5.727 bệnh nhân
- Tỷ lệ tái nhập viện: 24,99%
- Được giữ độc lập, chỉ dùng để đánh giá cuối cùng.

→ Patient-level split theo subject_id → không có bệnh nhân trùng giữa Train, Validation và Test.



Sử dụng mô hình baseline

Cấu hình mô hình Baseline – Logistic Regression

Thành phần	Cấu hình
Mô hình	Logistic Regression
Training data	42.045 admissions
Input	111 features
max_iter	1000
random_state	42
Class weighting	Chưa áp dụng
Hyperparameter tuning	Chưa thực hiện
Threshold ban đầu	0.50
Đánh giá hiện tại	Validation set

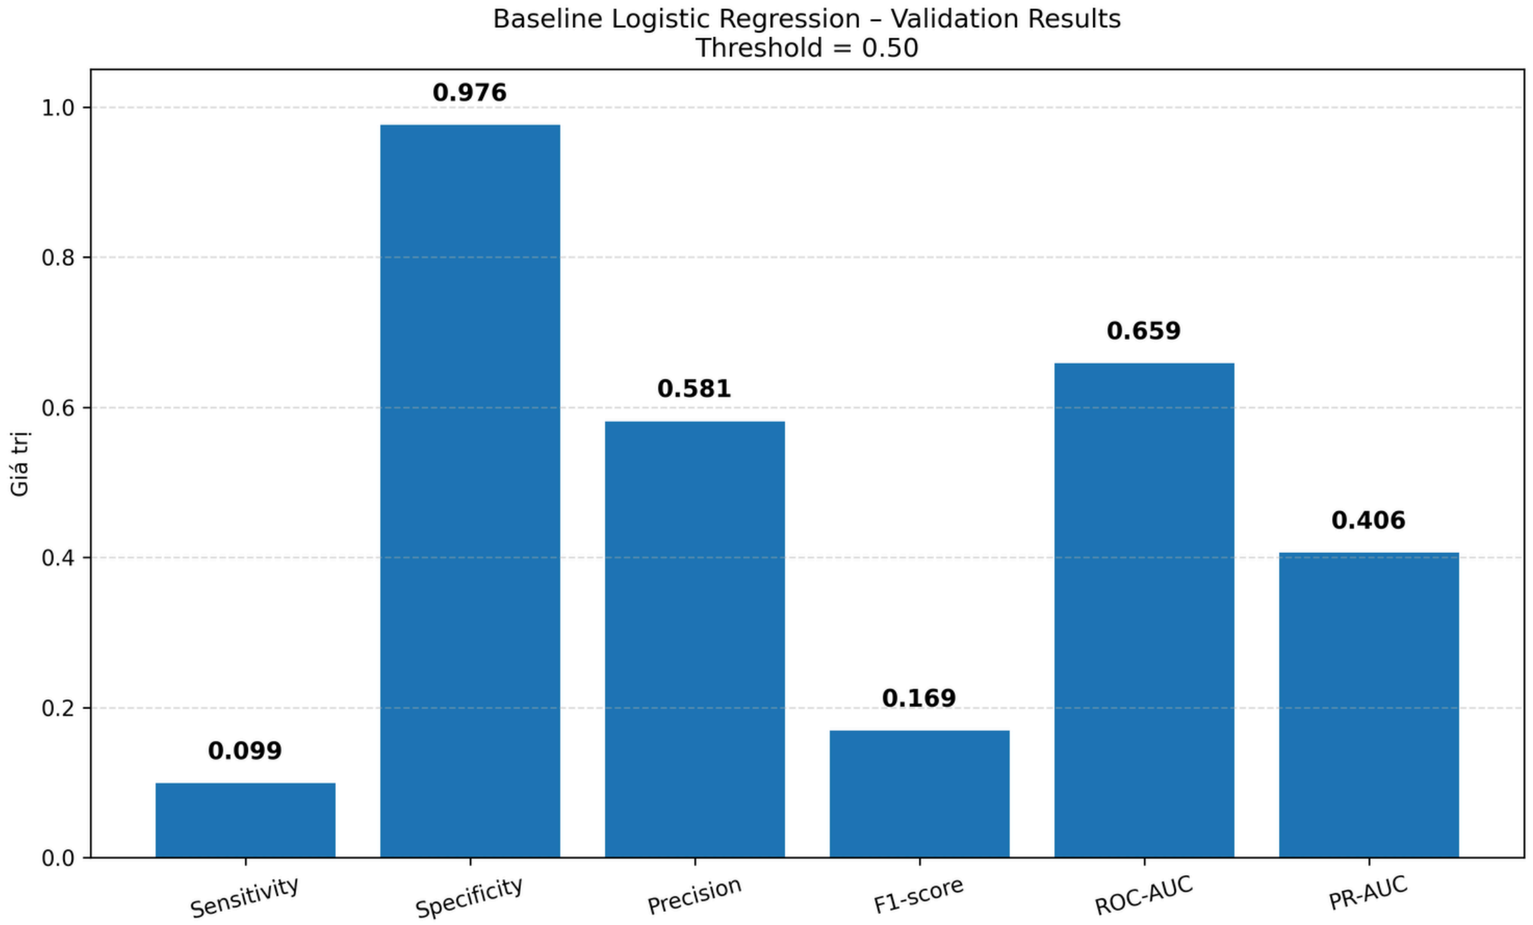
→ Vai trò của baseline: tạo mốc tham chiếu đơn giản, dễ giải thích để đánh giá mức cải thiện của Random Forest, XGBoost và LightGBM ở các bước tiếp theo.

Sử dụng mô hình baseline

Baseline Model – Logistic Regression

Kết quả:

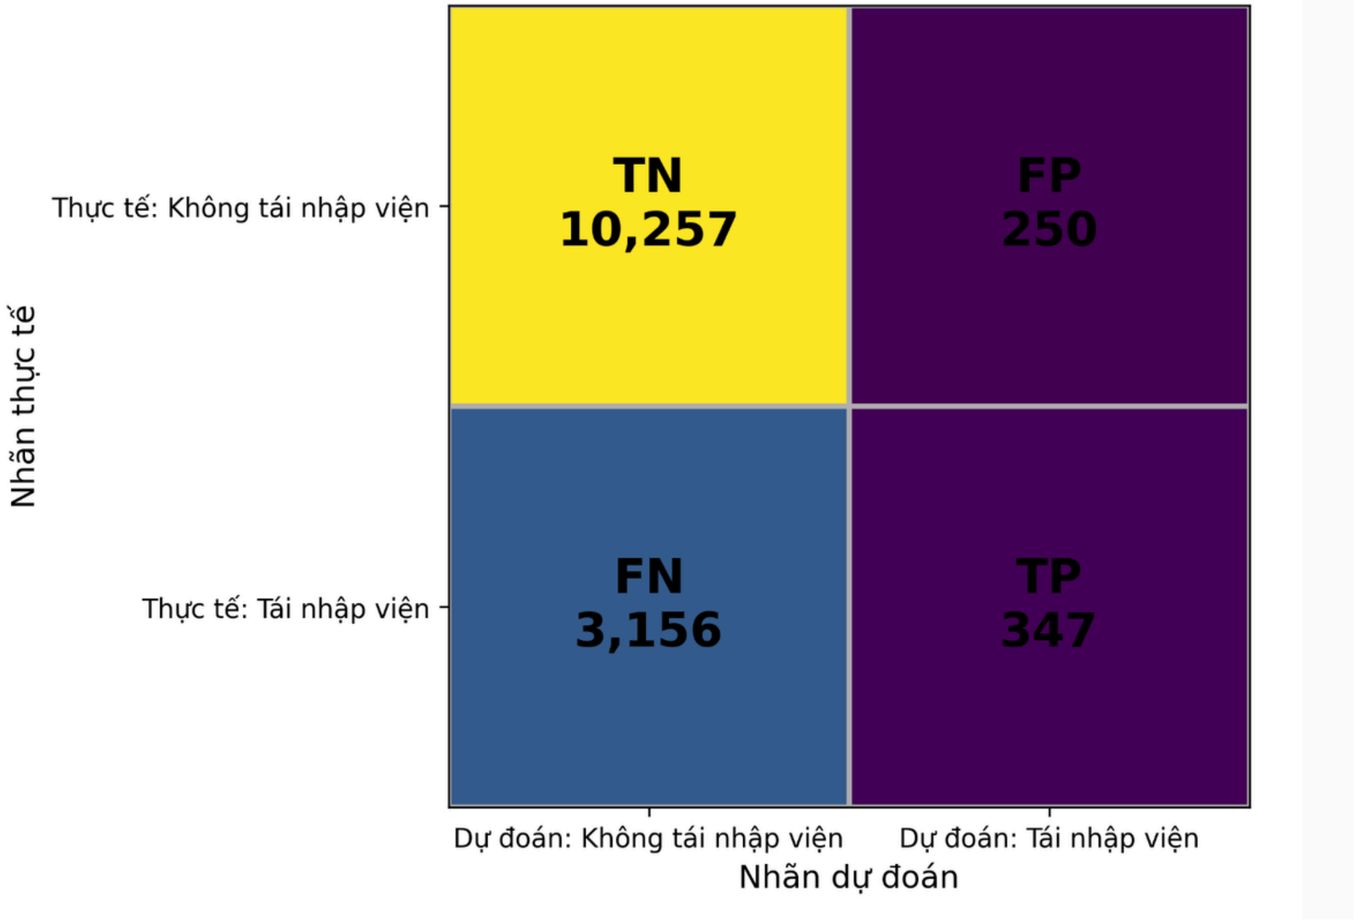
- Specificity rất cao → model nhận diện rất tốt những người không tái nhập viện.
- ROC-AUC = 0.6586 nghĩa là model vẫn có khả năng xếp hạng nguy cơ. Vấn đề lớn hiện tại là Threshold 0.50 chưa phù hợp với mục tiêu ưu tiên Recall



Sử dụng mô hình baseline

Baseline Logistic Regression – Validation Results

- Trong 3.503 lượt nhập viện thực sự tái nhập viện trong 30 ngày ở tập Validation, mô hình phát hiện đúng 347 và bỏ sót 3.156.
- Threshold 0.50 cho specificity cao nhưng sensitivity rất thấp → cần tối ưu threshold trên Validation để giảm False Negative.



TIMELINE

Thời gian	Công việc chính
Tuần 1-3	Khảo sát y văn, thu thập và khám phá dữ liệu EHR (EDA).
Tuần 4-6	Tiền xử lý (Patient-level split, điền khuyết) và xây dựng mô hình cơ sở.
Tuần 7-10	Huấn luyện, tối ưu mô hình (XGBoost/LightGBM) tập trung vào độ nhạy (Recall).
Tuần 11-12	Đánh giá sai số và trực quan hóa khả năng giải thích bằng XAI (TreeSHAP).
Tuần 13-15	Hoàn thiện báo cáo chuẩn IEEE, dọn dẹp mã nguồn và bảo vệ đề tài.

Workflow


gd1-proposal (T1-2)
Đọc 4 bài hạt giống
+ 1 bài khởi động
Sàng lọc bổ sung
≥6 bài (DOI chuẩn)
Viết đề cương: I/O,
chi phí FP/FN
gd2-dataset-eda (T2-3)
Tải dữ liệu EHR
(MIMIC-IV / Kaggle)
EDA: phân bố tuổi, EF,
eGFR, nhãn 30d
gd3-preprocessing (T4-5)
Chia Patient-level
split theo patient_id
assert 0 patient_id
trùng giữa Train/Test
Điền khuyết MICE/KNN,
chuẩn hóa CHỈ fit Train
gd4-baseline (T5-6)
Baseline bắt buộc:
Logistic Regression
Baseline mô hình cây:
Random Forest
gd5-proposed (T7-10)
Kiến trúc đề xuất:
XGBoost / Stacking
Ablation Study
(Nghiên cứu cắt bỏ)
W&B tracking,
Early Stopping
gd6-eval-xai (T10-12)
Đa độ đo +
Bootstrap 95% CI
SHAP Beeswarm +
Waterfall (≥3 TP, ≥2 FP/FN)
gd7-ieee-paper (T12-15)
Báo cáo IMRAD chuẩn IEEE
(bàn luận rủi ro sụt giảm AUC)
README tái lập Colab
+ Slide nghiệm thu

HUST

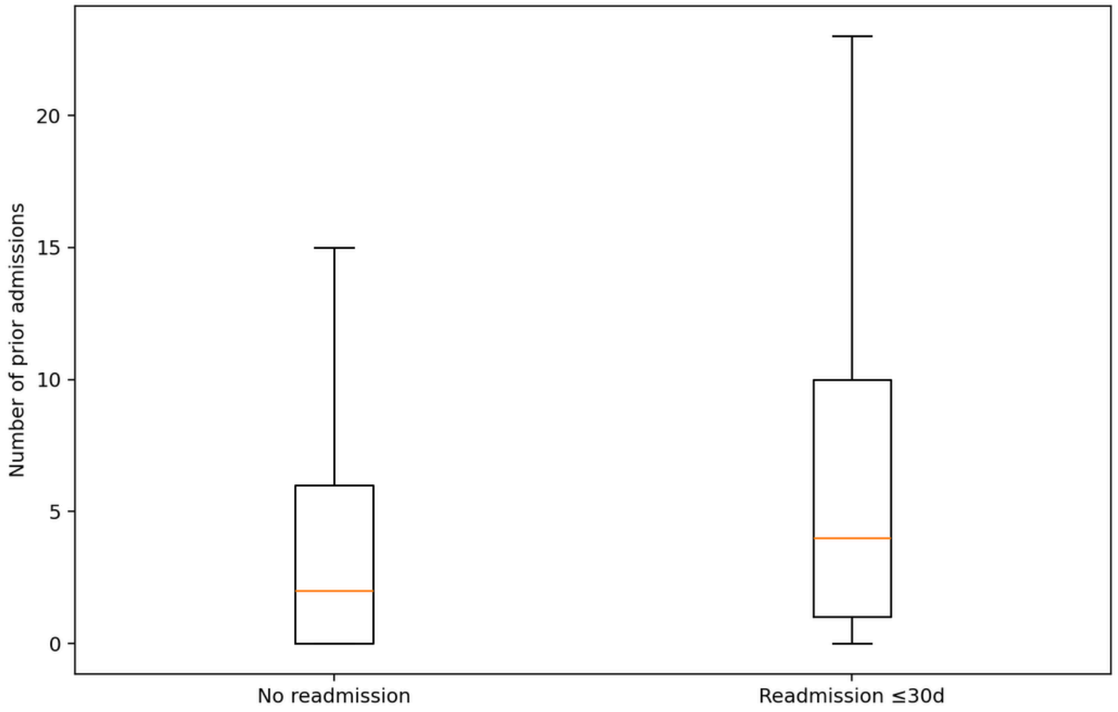
hust.edu.vn fb.com/dhbkhn

THANK YOU !

EDA

So sánh nhóm Readmission và Non-readmission

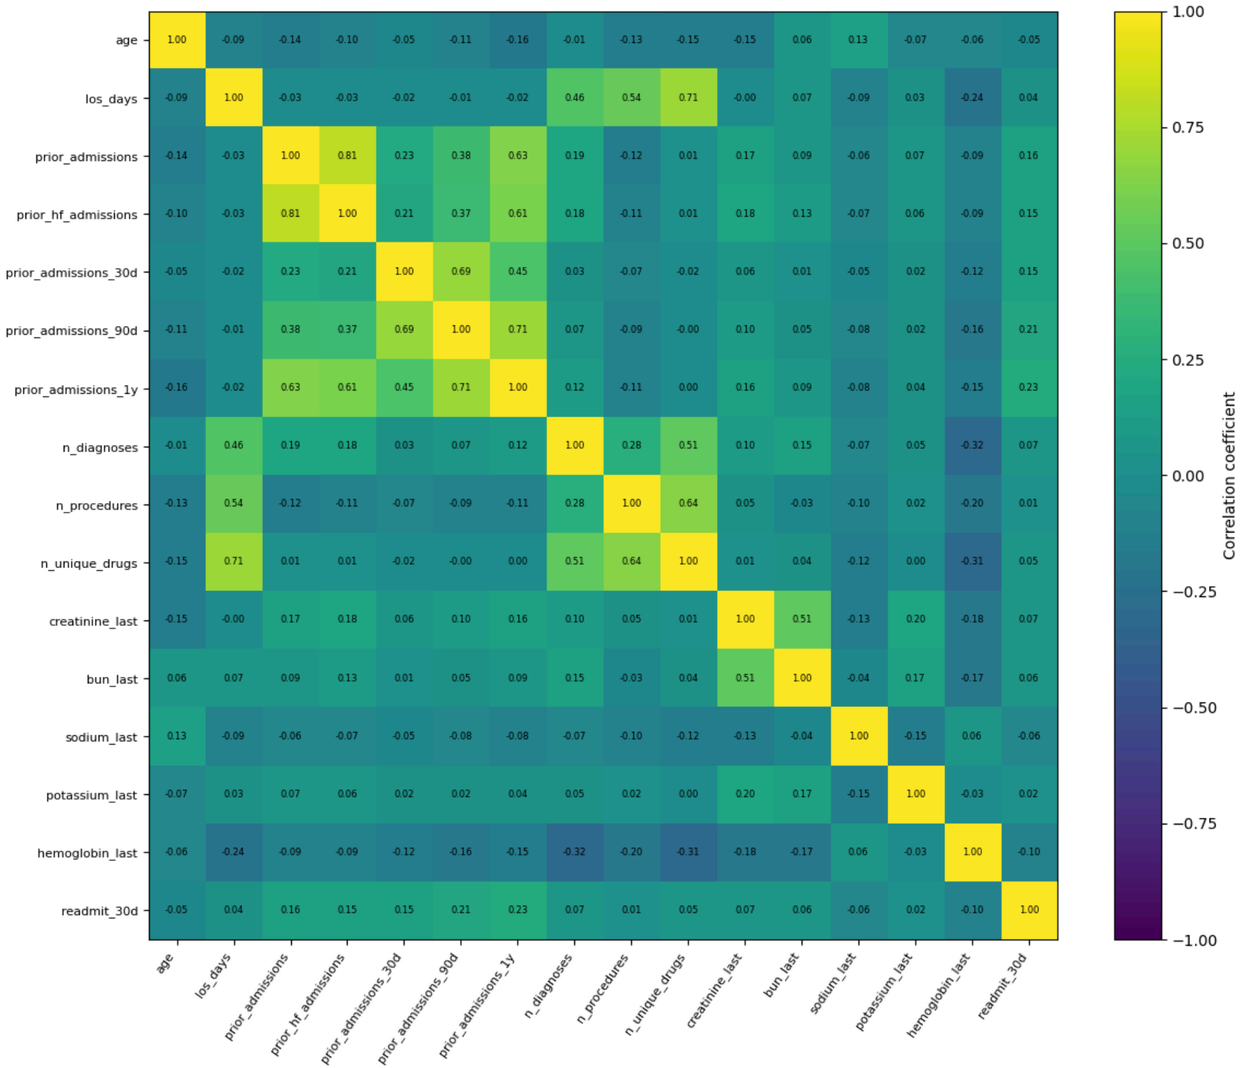
Feature	No Readmission	Readmission ≤30d
Age	75	73
LOS	4.95 ngày	5.48 ngày
Prior admissions	2	4
Prior HF admissions	1	2
Diagnoses	18	19
Creatinine	1.2	1.3
Hemoglobin	10.3	9.8



- Tiền sử nhập viện là nhóm đặc trưng cho thấy khác biệt rõ giữa hai nhóm
- Nhóm tái nhập viện có số lần nhập viện trước cao hơn.

EDA – Missing Data & Correlation Analysis

- BMI–Weight: r ≈ 0.85, nhưng cả hai đã bị loại do missing cao.
- Prior admissions – Prior HF admissions: r ≈ 0.81 → giữ tạm vì mang ý nghĩa lâm sàng khác nhau.
- Correlation chỉ phản ánh liên hệ thống kê, không chứng minh quan hệ nhân quả.



TIMELINE

Giai đoạn	Công việc chính	Trạng thái
Tuần 1–3	Khảo sát y văn, MIMIC-IV access , Xây cohort, EDA	✓ **Hoàn thành**
Tuần 4–5	Feature engineering, Missing data, Patient-level split, Train-only preprocessing	✓ **Hoàn thành**
Tuần 5–6	Logistic Regression baseline, Đánh giá trên Validation	✓ **Hoàn thành**
Tuần 7–10	Tối ưu threshold, Random Forest / XGBoost / LightGBM, So sánh mô hình	→ **Tiếp theo**
Tuần 10–12	Đánh giá Test: 95% CI, Calibration, Fairness, SHAP / error analysis	○ **Kế hoạch**
Tuần 12–15	Hoàn thiện báo cáo IEEE và up lên GitHub	○ **Kế hoạch**